

第6回: チャットUI + マルチターン会話

LLMアプリケーション基礎

今日のゴール

ブラウザで動く **チャット画面** を作り、AIが「前の発言を覚えている」状態を実現する

今日の流れ


前半

- チャットUIの設計（HTML/CSS でメッセージバブル）
- fetch で1往復してみる

後半

- マルチターン会話 — `messages` 配列に履歴を積む
- トークン と コンテキストウィンドウ の直感
- 演習: 1会話・メモリ保持版（リロードで消える）を完成させる

chat-app の全体像



今日は左(ブラウザ)に チャット画面 を作り、中央に 会話履歴(メモリ) を持たせる

前回までの状況

- 第5回で `POST /api/chat` の **バックエンド** ができた
- でも Swagger UI から1回ずつ叩くだけだった
- 「会話」というより「1往復ずつのお問い合わせフォーム」
- 今日: ブラウザに **チャットらしい画面** を載せ、**話の流れ** を持たせる

完成イメージ(第6回時点)

第6回 完成イメージ — 1つの会話・ブラウザの中だけ



まだ作らないもの(第7回以降)

- サイドバー / 会話の切り替え → 第8回
- DBに会話を保存 → 第7回
- リロードしても残る → 第7回

今日は 1つの会話だけ・ブラウザの中だけ に集中する。


前半: チャットUIを組む

チャット画面の3パーツ

1. メッセージリスト — 上に積み上がる発言の流れ
2. 入力欄 — 下にあるテキストエリアと送信ボタン
3. メッセージバブル — 1つ1つの発言の吹き出し

この3つだけ作れば「チャットっぽい画面」になる。

画面のレイアウト(縦に積む)



- `display: flex; flex-direction: column;`
- リスト部分だけが `flex: 1` で伸び縮みする

メッセージバブルの構造

```
<div class="message user">
  <div class="message-bubble">こんにちは</div>
</div>

<div class="message assistant">
  <div class="message-bubble">こんにちは!</div>
</div>
```

- 外側の `.message` で 左右どっち寄せ かを決める
- 内側の `.message-bubble` で 色と形 を決める

バブルの色分けイメージ

メッセージバブル: 左 = assistant ・ 右 = user



外側の `.message` で左右の寄せを決め、内側の `.message-bubble` で色と形を決める

- `align-self: flex-end` で user は右寄せ
- `align-self: flex-start` で assistant は左寄せ

CSS のキモ(抜粋)

```
.message.user {  
  align-self: flex-end; /* 右寄せ */  
}  
.message.user .message-bubble {  
  background-color: #2563eb; /* 青 */  
  color: white;  
}  
  
.message.assistant {  
  align-self: flex-start; /* 左寄せ */  
}  
.message.assistant .message-bubble {  
  background-color: #f3f4f6; /* 灰 */  
}
```

入力欄: textarea + button

```
<form id="chat-form" class="input-area">
  <textarea
    id="chat-input"
    rows="2"
    placeholder="メッセージを入力..."
  ></textarea>
  <button type="submit">送信</button>
</form>
```

- `<input>` ではなく `<textarea>` を使うのが定番
- 長文や改行を入れたいことが多いから

キー操作のお作法

- **Enter** で送信
- **Shift+Enter** で改行
- 日本語の変換確定の Enter では送信しない (`isComposing`)

```
input.addEventListener("keydown", (e) => {  
  // isComposing = 日本語入力(IME)で変換中かどうか  
  if (e.key === "Enter" && !e.shiftKey && !e.isComposing) {  
    e.preventDefault(); // 改行をキャンセル  
    sendMessage();  
  }  
});
```

ChatGPT などほとんどのチャットUIがこの挙動。

fetch で1往復(まずは最小形)

```
async function sendOnce(text) {
  const res = await fetch("/api/chat", {
    method: "POST",
    headers: { "Content-Type": "application/json" },
    body: JSON.stringify({ messages: [{ role: "user", content: text }] }),
  });
  const data = await res.json();
  return data.reply;
}
```

- これだけだと 1往復で会話が途切れる(AIは前の発言を忘れる)
- → ここから「履歴を持つ」話に進む

後半: マルチターン会話

マルチターンとは

- マルチターン (multi-turn) 会話 = 何往復もする会話
- 「前の発言を踏まえて答えてほしい」
- 例:
 - User: 「私の名前は田中です」
 - AI: 「よろしくお願いします」
 - User: 「私の名前は何でしたか？」
 - AI: 「田中さんですね」 ← これを実現したい

LLM API の重要な性質: ステートレス

- OpenAI の API は 過去のやり取りを記憶しない
- 1回のリクエストは、それ単独で完結している
- サーバは「あなたが誰か」「前に何を話したか」を 覚えていない

リクエスト1: 「私の名前は田中です」 → 「よろしく」
リクエスト2: 「名前は？」 → 「???' (何も知らない)

どうすれば「覚えている」ように見せるか

LLM API はステートレス — 「覚えている」は錯覚

☒ 今回の発言だけ送る

2往復目のリクエスト

user: 「私の名前は?」

↓ OpenAI に送る

「???」 (LLMは過去を知らない)
→ デタラメ or 「分かりません」

☒ 過去全部を毎回 送る

2往復目のリクエスト (messages 配列)

system: 「丁寧なアシスタント」

user: 「私の名前は田中です」

assistant: 「よろしくお願いします」

user: 「私の名前は?」 ← 今回の発言

↓ OpenAI に丸ごと送る

「田中さんですね」

→ 文脈から推論できる✓

フロント (or サーバ) が履歴を保持し、毎回まるごと送る

= 「覚えている」ように見せる仕組み

OpenAI サーバは「あなたが誰か / 前に何を話したか」を一切記憶しない。1リクエスト=独立したやり取り。

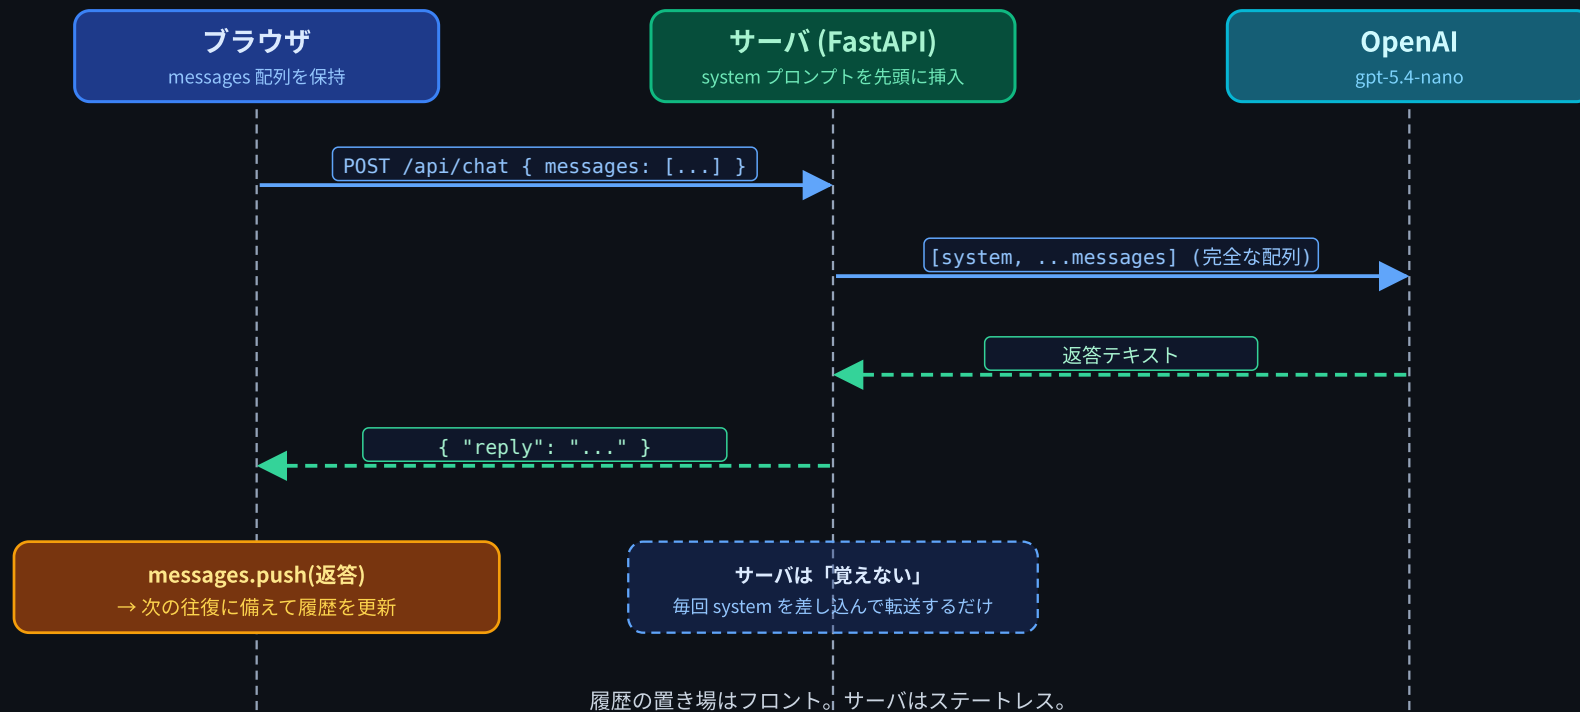
messages 配列の役割

```
let messages = [  
  { role: "user",    content: "..."} ,  
  { role: "assistant", content: "..."} ,  
  { role: "user",    content: "..."} ,  
  ...  
];
```

- フロントが 会話履歴を全部記憶しておく 変数
- 発言があるたびに push する
- 送信時には これを丸ごとサーバに渡す

今回の役割分担

役割分担: ブラウザが履歴を保持・サーバは system 挿入のみ



サーバは 覚えない。フロントが履歴の置き場。

送信のシーケンス(1往復ぶん)

ユーザーが入力 → 送信ボタン

- 1. `messages.push({role:"user", content:入力})`
- 2. 画面にユーザー発言を表示
- 3. 「考え中…」表示



`fetch("/api/chat", { body: {messages} })`

- サーバ: `system + messages` を OpenAI に渡す
- サーバ: 返答テキストだけ返す



`return {reply: "..."}`

- 4. `messages.push({role:"assistant", content:reply})`
- 5. 「考え中…」を返答で置き換え

コードの本体(抜粋)

```
async function sendMessage() {
  const content = input.value.trim();

  messages.push({ role: "user", content }); // 履歴に追加
  appendMessage("user", content); // 画面に追加
  const loading = appendMessage("assistant", "考え中...", "loading");

  const res = await fetch("/api/chat", {
    method: "POST",
    headers: { "Content-Type": "application/json" },
    body: JSON.stringify({ messages }), // 履歴を丸ごと送る
  });
  const { reply } = await res.json();

  messages.push({ role: "assistant", content: reply });
  loading.querySelector(".message-bubble").textContent = reply;
}
```


`/api/chat` のリクエストスキーマが変わる

第5回までの `POST /api/chat` は **単発の質問** を受け取っていた:

```
{ "message": "こんにちは" }
```

第6回からは **会話履歴をまるごと** 受け取る形に変える:

```
{
  "messages": [
    { "role": "user",      "content": "私の名前は田中です" },
    { "role": "assistant", "content": "よろしくお願いします" },
    { "role": "user",      "content": "名前は?" }
  ]
}
```

なぜ変える?: 履歴を毎回送らないとAIは前の発言を覚えてくれないから。

Pydantic モデルも書き換える

第5回の `ChatRequest(message: str)` は捨てて、新しい形に置き換える:

```
class Message(BaseModel):
    role: str = Field(pattern="^(user|assistant)$")
    content: str = Field(min_length=1, max_length=4000)

class ChatRequest(BaseModel):
    messages: list[Message] = Field(min_length=1)
```

- `Message` = 1発言ぶん (`role` + `content`)
- `ChatRequest` = その配列を1つ持つだけ
- `role` は `"user"` か `"assistant"` のどちらかに限定

これでフロントから来る JSON をそのまま型チェックできる。

サーバ側はびっくりするほどシンプル

```
@app.post("/api/chat")
def chat(req: ChatRequest):
    # system を先頭に差し込む
    messages_for_api = [{"role": "system", "content": SYSTEM_PROMPT}]
    for m in req.messages:
        messages_for_api.append({"role": m.role, "content": m.content})

    response = client.chat.completions.create(
        model="gpt-5.4-nano",
        messages=messages_for_api,
        reasoning_effort="low",
    )
    return {"reply": response.choices[0].message.content}
```

サーバは 履歴を持たない。覚えてるのはフロントだけ。

なぜ system はサーバ側で差し込む？

- システムプロンプトはアプリの性格を決める大事な設定
- フロントから自由に書き換えられたら、AIの振る舞いを乗っ取られる
- 「絶対に変えてほしくないもの」は **サーバ側で固定** する
- 第8回で「会話ごとに system を変える」のもサーバ管理

ここで重要な気付き

■ 会話が長くなるほど、毎回送るデータも長くなっていく

- 5往復目では「過去5往復ぶん全部」を毎回送っている
- 50往復目では「過去50往復ぶん全部」を毎回送っている
- これがLLMアプリの **本質的な特性**

→ 「トークン」と「コンテキストウィンドウ」の話につながる

トークンとコンテキストウィンドウ

LLM は「文字」を見ていない

- LLM が見ているのは トークン (token) という単位
- 文章をトークンに分解してから処理する
- 英語: 単語1個 $\equiv$ 1トークン(ざっくり)
- 日本語: 1文字 $\equiv$ 1~2トークン(ざっくり)
- 「次のトークンを予測する」のがLLMの仕事(第1回でやった)

トークン分割のイメージ

英語:

```
"Hello, world!" → [Hello] [,] [ world] [!] = 4トークン
```

日本語:

```
"こんにちは" → [こん] [にち] [は] = 3トークン  
"今日はいい天気" → [今日] [は] [いい] [天気] = 4トークン
```

※ 実際の分割はモデルのトークナイザに依る。あくまでイメージ。

なぜトークンが大事？

LLMの世界では、ほとんどすべてが **トークン基準**で測られる:

何	単位
料金	100万トークンあたり \$
速度	1秒あたり何トークン生成できるか
入力の上限	コンテキストウィンドウ = 何トークンまで詰めるか
出力の上限	1回の返答で最大何トークン

→ 文字数ではなく、トークン数の感覚を持つ

gpt-5.4-nano のスペック


- 入力: \$0.20 / 1Mトークン
- 出力: \$1.25 / 1Mトークン
- コンテキストウィンドウ: 400K トークン
- 最大出力: 128K トークン

「コンテキストウィンドウ」= 1回のリクエストに詰め込める最大トークン数

system + 会話履歴 + 新しい質問 が全部この枠の中に入る必要がある。

コンテキストウィンドウのイメージ

コンテキストウィンドウ: 1リクエストの上限トークン数



↓

ここが膨らんで上限を超えるとエラー

会話が長くなると何が起きる？

毎ターン、過去の履歴を **全部** 送り直す設計だから：

- (a) 送信トークン量が増える → リクエストごとの料金が上がる
- (b) コンテキストウィンドウの上限に近づく → 上限超えるとエラー
- (c) 応答が遅くなる → 処理する量が増える

短い会話なら気にならないが、長文を貼り続けると一気に消費する。

ざっくり感覚を持つ

`gpt-5.4-nano` 入力 \$0.20 / 1Mトークン:

やり取り規模	累積入力トークン (目安)	料金感
5往復 (短文)	~500	ほぼ0円
50往復 (短文)	~25,000	\$0.005
1万字の文書を貼って5往復	~50,000	\$0.01
400Kウィンドウぎりぎり	400,000	\$0.08 (1回)

普段は気にしなくていい。でも 「貼り付けは重い」 ことだけは知っておく。

DevTools で実際に見てみよう (演習中)


1. F12 で DevTools を開く
2. **Network** タブ を選ぶ
3. 何往復か会話する
4. リストに並ぶ `chat` を1つ目→2つ目→... の順にクリック
5. **Payload** を見ると `messages` 配列が 毎回長くなっている

さらに Console で:

```
__debug.show(); // フロント側の messages を直接覗く
```

「毎回まるごと送る」の確認

messages 配列は毎ターン伸びていく → トークン量も伸びる



↑ DevTools の Network タブで Payload の messages が「毎回長くなる」のを目で観察してみる

これがコスト・速度の本質的な要因 — トークン量で全てが決まる世界

演習

今日の演習

`session06/exercise/` の chat-app を起動して、次の3つを体験する:

1. マルチターン会話: 名前を覚えてくれることを確認
2. リロードで消える: ブラウザを更新すると会話が消える
3. **Payload**観察: DevTools で `messages` が長くなる様子

`exercise/README.md` の手順に沿って進める。

起動手順(おさらい)

```
# 1. APIキーを export
export OPENAI_API_KEY=sk-...

# 2. 依存パッケージ(初回のみ)
pip install -r requirements.txt

# 3. サーバ起動
cd session06/exercise
python main.py
```

ブラウザで `http://localhost:8000` を開く。

余裕がある人向け: 改造アイデア

- system プロンプトを書き換えて性格を変えてみる(関西弁、ツンデレ等)
- 「リセット」ボタンを追加して `messages = []` に戻す
- ヘッダーに今のメッセージ数 (`messages.length`) を表示する
- 入力欄を Markdown 対応にしてみる(`marked.js` 等)

第8回までに必須なのは「マルチターンで動くこと」だけ。

本日のまとめ

学んだこと

1. チャットUI = メッセージリスト + 入力欄 + バブル
2. LLM API はステートレス — サーバは過去を覚えてない
3. 「覚えている」ように見せる = 毎回 **messages** 配列ごと送る
4. 会話が長くなる $\Rightarrow$ 送信トークンが増える
5. `gpt-5.4-nano` のコンテキストウィンドウは **400K** と広いが無限ではない

次回予告

第7回: 履歴の永続化 (SQLite)

問題: リロードで会話が消える。解決策はサーバ側で **SQLite** に保存すること。 `messages` テーブルを作って発言を保存し、起動時に過去ログを読み込んで画面に復元する。フロントが履歴を持って送るのはやめ、サーバ管理に切り替える。

提出物

実習で作成したファイルをフォームから提出してください:

1. `session06/exercise/` の chat-app (マルチターン版) の GitHub のURL
 - 例: `https://github.com/ユーザー名/リポジトリ名/tree/main/session06/exercise`

お疲れ様でした！